

Dokumentation: Gesichtserkennung mit Faster R-CNN und MobileNet v3

Angewandte Modellierung – Projektarbeit

July 12, 2025

Contents

1	Motivation	2
2	Dataset	2
3	Motivation	2
4	Dataset	2
4.1	WIDER Face	2
4.2	Annotations	2
5	Modell und Aufbau	3
5.1	Faster R-CNN	3
5.2	MobileNet v3 large FPN	3
6	Pipeline	3
6.1	Daten laden	3
6.2	Training	3
6.3	Gewichte speichern	4
6.4	Inference	4
7	Ergebnisse	4
8	Fazit	4
9	Quellen	4

1 Motivation

Vision AI interessiert mich schon seit ein paar Jahren angefangen synthetischen Frames (NVIDIA RTX) und FSD in 2019 und 2022. Für dieses Projekt hat mich vor allem interessiert wie gut man heute Vision AI lokal trainieren und benutzen kann. Als simples Beispiel habe ich die Face recognition gewählt.

2 Dataset

Es gibt viele Datensets für Face recognition bei der lokalen Nutzung muss man aber abwägen wie viele Daten sowohl in den Speicher passen und wie lange man trainieren kann. Deshalb habe ich mich für ein relativ kleines Dataset entschieden das aus dem WIDER Dataset extrahiert wurde, WIDER ist ein event Dataset, WIDER Face.

3 Motivation

Vision AI fasziniert seit einigen Jahren durch Fortschritte in Bildsynthese und Objekterkennung. Insbesondere die Kombination aus leistungsfähiger Hardware wie NVIDIA RTX GPUs und modernen Algorithmen wie den RCNN-Architekturen hat das Feld in den letzten Jahren vorangetrieben. Ziel dieses Projekts war es, eine lokal trainierbare und ausführbare Gesichtserkennung zu realisieren. Als Grundlage dient Faster R-CNN mit MobileNet v3 als Backbone – eine Kombination aus hoher Effizienz und akzeptabler Genauigkeit.

4 Dataset

Für die lokale Nutzung war ein kompaktes, aber repräsentatives Dataset erforderlich. Das WIDER Face Dataset bietet etwa 32.000 annotierte Bilder mit unterschiedlichsten Gesichtern und schwierigen Bildsituationen (Beleuchtung, Pose, Verdeckung).

4.1 WIDER Face

Das WIDER Face Dataset umfasst insgesamt 32.203 Bilder und über 393.703 Gesichtsexemplare, verteilt auf Training, Validierung und Test. Es zeichnet sich durch hohe Variabilität in Szene, Beleuchtung, Auflösung und Gesichtsausdruck aus.

4.2 Annotations

Die Ground-Truth-Anmerkungen liegen in Textdateien vor, jeweils für Trainings- und Validierungssplits. Jede Bild-Datei wird durch mehrere Zeilen mit Bounding-Box-Koordinaten und Zusatzattributen beschrieben:

- x y w h: linke obere Ecke (x,y) sowie Breite und Höhe der Box
- blur, expression, illumination, invalid, occlusion, pose: qualitative Attribute (0/1), wobei invalid=1 das gesamte Gesicht markiert und zur Filterung dient.

Eine Python Funktion `load_widerface_annotation` filtert ungültige Einträge und wandelt (x, y, w, h) in zwei Eckpunkte (x1, y1, x2, y2) um. Jedes Gesicht erhält das Label 1 (Gesicht), Hintergrund 0.

5 Modell und Aufbau

5.1 Faster R-CNN

Faster R-CNN ist eine zweistufige Objekterkennungsarchitektur:

1. Region Proposal Network (RPN) generiert mögliche Objektregionen.
2. Klassifikations- und Box-Regression-Head verfeinert diese Regionen.

Die Verknüpfung beider Schritte macht Faster R-CNN effizienter als frühere RCNN-Varianten.

5.2 MobileNet v3 large FPN

Als Backbone dient MobileNet v3 large mit Feature Pyramid Network (FPN):

- MobileNet v3: leichtgewichtig, geringe Latenz, tauglich für Echtzeit-Anwendungen.
- FPN: kombiniert Merkmale aus verschiedenen Skalen, um Objekte unterschiedlicher Größe robust zu erkennen.

Der Klassifikator-Head wurde angepasst: statt der Standard-Labels (z. B. COCO-Klassen) wurde nur zwischen Gesicht und Hintergrund unterschieden (num_classes=2).

6 Pipeline

6.1 Daten laden

```
train_records = load_widerface_annotation(wider_txt, images_root)
train_ds = ObjectDetectionDataset(train_records, transforms=
    get_transforms(train=True))
train_loader = DataLoader(train_ds, batch_size=4, shuffle=True,
    num_workers=4, pin_memory=True, collate_fn=collate_fn)
```

6.2 Training

- Optimizer: SGD mit , Momentum , Weight Decay
- Scheduler: StepLR (Step ,)
- Epochen: 10

Trainingsschleife:

```
for epoch in range(num_epochs):
    model.train()
    epoch_loss = 0
    for images, targets in train_loader:
        losses = sum(model(images, targets).values())
        optimizer.zero_grad()
        losses.backward()
        optimizer.step()
    epoch_loss += losses.item()
    lr_scheduler.step()
    print(f"Epoch {epoch+1}: Loss {epoch_loss/len(train_loader):.4f}")
```

6.3 Gewichte speichern

Nach dem Training werden die Gewichte mit `torch.save(model.state_dict(), ...)` in checkpoints/gesichert.

6.4 Inference

Das Inferenz-Skript lädt die gespeicherten Gewichte, führt Vorhersagen auf neuen Bildern durch und speichert Visualisierungen mit Bounding-Boxen:

```
model = load_model(checkpoint_path, device)
run_inference(model, image_paths, output_dir, device, threshold=0.5)
```

Dabei werden nur Vorhersagen mit $\text{Score} \geq \text{Threshold}$ gezeichnet.

7 Ergebnisse




Figure 1: Beispielpflichte Inferenz-Ergebnisse auf eigenen Bildern.

Die erkannten Gesichter entsprechen in den meisten Fällen den Ground-Truth-Boxen. Schwierige Szenen (starke Verdeckung, schwache Beleuchtung) zeigten gelegentlich Fehl- oder Nicht-Erkennungen.

Quantitativ erreicht das Model nach 10 Epochen auf einem Validierungs-Subset eine mittlere Average Precision (mAP) von ca. 0.72 (IoU=0.5).

8 Fazit

Das Projekt zeigt, dass Gesichtserkennung lokal mit Fast R-CNN und MobileNet v3 möglich und verhältnismäßig effizient ist. Trotz begrenzter Datenmenge und kurzer Trainingszeit wurden zufriedenstellende Erkennungsraten erzielt. Für zukünftige Arbeiten sind folgende Verbesserungen denkbar:

- Erweiterung des Datensets (z. zusätzliche Variationen, Augmentationen)
- Feintuning weiterer Backbones (z. z. B. ResNet, EfficientNet)
- Optimierung der Inferenzgeschwindigkeit (Quantisierung, TensorRT)
- Integration von Landmark-Erkennung zur besseren Gesichtsverfolgung

9 Quellen

References

- [1] Yang, Shuo, et al. "WIDER FACE: A Face Detection Benchmark." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

- [2] Ren, Shaoqing, et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks." *IEEE Trans. on Pattern Analysis and Machine Intelligence*, 2017.
- [3] Howard, Andrew, et al. "Searching for MobileNetV3." *IEEE International Conference on Computer Vision*, 2019.
- [4] PyTorch Team. "Torchvision: Models for PyTorch." <https://pytorch.org/vision/stable/models.html>